

寄存 token 在机器人价值模型中的变体消融： 位置、时序拓扑与因果泄漏

WCM 项目

2026 年 9 月

摘要

空间寄存器（register tokens, Darcet et al. 2023）已被证明可缓解视觉 Transformer 的注意力伪影。本文在机器人操作的价值模型（value model）上，系统消融 register tokens 的四种变体：ViT 内空间放置（D2）、latent 层前缀读出、双处独立注入、以及块因果注意力中的同层融合（块粒度可调）。在严格因果约束下，三 seed 重复实验与 27,727 窗口的独立同分布测试集表明：(i) 各寄存变体相对无寄存基线**无显著增益**（差异与 seed 方差同量级）；(ii) 训练期 SOTA 表现主要来自注意力掩码中 5% 的随机未来泄漏与块内双向的确定性泄漏——价值预测任务对微小因果破缺的敏感度远超自监督任务；(iii) 旧评估口径（724 窗口 val、单 seed early-stop）会将上述噪声量级差异夸大为 10%–26% 的“结构收益”。我们据此给出时序 value 学习中结构消融的评估方法论：独立测试集、多 seed 均值、以及默认执行的泄漏消融。

1 引言

2 相关工作

2.1 寄存 token 与注意力伪影

2.2 块因果注意力与稀疏化

2.3 价值模型与泄漏

3 方法

3.1 基线与变体

3.2 块因果注意力掩码与泄漏机制

3.3 训练配置

4 实验

4.1 评估口径

4.2 多 seed 结果

4.3 泄漏剂量-响应

4.4 独立测试集重排

4.5 OOD 泛化

5 讨论

6 结论

参考文献